

پاسخ سری اول تمرینات درس یادگیری ماشین

امیرحسین رمضانی بناب (۹۹۲۱۰۲۹۴)

۱ سوال اول

بدون کاسته شدن از کلیت فرض میکنیم در صورتی که خروجی پرتاب سکه H باشد پیش بینی برد بازیکن اول، و در صورت خروجی T پیش بینی برد بازیکن دوم آن بازی است.

برای پاسخ به این سوال ابتدا ثابت میکنیم احتمال پیش بینی صحیح یک بازی در دور i برابر $\frac{1}{2^i}$ است. بدین منظور از استقرا استفاده میکنیم.

- پایهی استقرا: احتمال پیش بینی صحیح هر بازی در دور اول برابر $\frac{1}{2}$ است: برای اثبات این ادعا فضای پیشامد برای هر بازی را به شکل زیر در نظر میگیریم.

$$\Omega = \{(P_1, H), (P_1, T), (P_2, H), (P_2, T)\}$$


در هر زوج مرتب، مولفه‌ی اول نشان دهنده بازیکن برنده بازی و مولفه‌ی دوم نشان دهنده نتیجه‌ی پرتاب سکه است. حالت‌هایی که پیش بینی به درستی انجام می‌شود به شکل زیر است:

$$A = \{(P_1, H), (P_2, T)\}$$

پس احتمال پیش بینی صحیح هر بازی برابر $\frac{|A|}{|\Omega|}$ است که مساوی عدد $\frac{1}{2}$ است.

- فرض استقرا: احتمال پیش بینی صحیح یک بازی در دور i برابر $\frac{1}{2^i}$ است.

- حکم استقرا: احتمال پیش بینی صحیح یک بازی در دور $1 + i$ برابر $\frac{1}{2^{i+1}}$ است: برای اثبات این حکم ابتدا یک بازی در دور $1 + i$ در نظر می‌گیریم و آن را بازی f می‌نامیم. همچنین فرض میکنیم در جدول بازی‌ها تیم‌هایی که بازی f را انجام می‌دهند برنده‌گان بازی e_1 و e_2 هستند که این بازیکنان را نیز w_1 و w_2 می‌نامیم که به ترتیب برنده‌ی بازی e_1 و e_2 هستند که در بازی f به مصاف هم می‌روند.



اگر w_1 برنده‌ی بازی f باشد فقط در دو حالت ممکن است پیش بینی‌کننده به درستی این پیش بینی را انجام داده باشد.

حالت اول: بازی e_1 و e_2 به درستی پیش‌بینی شده باشند و بازی f هم به درستی پیش‌بینی شود. احتمال این رویداد طبق فرض استقرارا برابر عدد زیر است

$$\frac{1}{2^i} \times \frac{1}{2^i} \times \frac{1}{2}$$

حالت دوم: بازی e_1 به درستی پیش‌بینی شده باشد ولی پیش‌بینی بازی f درست نباشد. همچنین پیش‌بینی بازی f درست باشد و بازیکن w_1 در آن بازی برنده شده باشد. احتمال چنین رویدادی طبق فرض استقرارا برابر عدد زیر است.

$$\frac{1}{2^i} \times \left(1 - \frac{1}{2^i}\right) \times \frac{1}{2}$$

پس در کل در حالتی که w_1 برنده‌ی بازی f شود، به احتمال زیر پیش‌بینی درست است.

$$\frac{1}{2^i} \times \frac{1}{2^i} \times \frac{1}{2} + \frac{1}{2^i} \times \left(1 - \frac{1}{2^i}\right) \times \frac{1}{2} = \frac{1}{2^{i+1}}$$

همچنین در حالتی که w_2 برنده‌ی بازی شود با استدلالی مشابه به همین عدد می‌رسیم.

حال اگر احتمال پیش‌بینی صحیح را با $P(\text{TruePredict})$ نمایش دهیم و احتمال برنده شدن بازیکن w_i در بازی f را با $P(Wins_i)$ نمایش دهیم داریم :

$$P(\text{TruePredict}) = P(\text{TruePredict}|Wins_1)P(Wins_1) + P(\text{TruePredict}|Wins_2)P(Wins_2)$$

که با جایگذاری $P(Wins_i) = \frac{1}{2^{i+1}}$ و $P(\text{TruePredict}|Wins_i) = \frac{1}{2}$ داریم :

$$P(\text{TruePredict}) = \frac{1}{2^{i+1}} \times \frac{1}{2} + \frac{1}{2^{i+1}} \times \frac{1}{2} = \frac{1}{2^{i+1}}$$

پس حکم استقرارا اثبات شد.


حال کافی است میزان سود *Expected* پیش‌بینی‌کننده را محاسبه کنیم.

از آنجایی که در مرحله‌ی i ام $\frac{64}{2^i}$ بازی انجام می‌شود (n_i) و میزان سود متوسط از هر بازی در دور i ام برابر $\frac{1}{2^i}$ به دست آمد (e_i). پس میزان سود عایدی پیش‌بینی‌کننده در نهایت برابر است با :


$$E = \sum_{i=1}^6 n_i p_i = \sum_{i=1}^6 \frac{64}{2^i} \times \frac{1}{2^i} = 64 \sum_{i=1}^6 \frac{1}{2^{i+1}} = 64 \left(\frac{1}{2} \left(1 - \frac{1}{64}\right) \right) = 31.5$$

۲ سوال دوم

برای پاسخ به این سوال ابتدا سوال را ساده سازی می کنیم تا به مسئله‌ی ساده‌تری برسیم و آن را حل کنیم. صفحه را به شکل شیارهایی به ارتفاع d در نظر می‌گیریم که مرز بین هر دو شیار، خطوط موازی به فاصله d باشند. همچنین سوزن به طول L را معادل خط p در نظر می‌گیریم که مرکز آن در شیار α قرار دارد. به شکل زیر:



حال اگر p یکی از خطوط موازی روی کاغذ را قطع کند، معادل این است که یکی از دو خط موازی شیاری که مرکز p در آن دارد را قطع نماید. یعنی اگر خط p خطی از صفحه را قطع کند، یکی از خطوط شیار α که با رنگ بنفش مشخص شده‌اند را نیز قطع می‌کند و برعکس. در نتیجه به جای اینکه احتمال این را حساب کنیم که خط p از صفحه را قطع کند، روی یک شیار α متمرکز می‌شویم و احتمال قطع کردن یکی از دو خط بنفسنگ توسط خط p را محاسبه می‌کنیم. حال از آنجایی که خطوط افقی را می‌توانیم تا بی نهایت امتداد دهیم محل افقی مرکز خط p در احتمال خواسته شده هیچ تاثیری ندارد و هر دو نقطه‌ای که روی یک خط افقی در شیار α باشند، احتمال یکسانی را تولید می‌کنند. به این خاطر می‌توانیم دوباره مسئله را ساده سازی کنیم و به یک خط عمودی روی شیار فکر کنیم:




در نهایت یک مرحله دیگر ساده سازی وجود دارد. احتمال آنکه خط p به مرکز C خطی از دو خط موازی تشکیل دهنده‌ی شیار α را قطع کند، معادل این احتمال است که خط p به مرکز C یکی از دو خط موازی تشکیل دهنده‌ی شیار α را قطع کند که به C نزدیک تر است. یعنی وقتی p خطی از شیار را قطع می‌کند، قطعاً خط نزدیک تر را نیز قطع می‌کند و برعکس وقتی خط نزدیک تر را قطع می‌کند، خطی از شیار را قطع کرده است.

پس به جای یک شیار روی نصف شیار متمرکز می‌شویم و تحلیل نهایی را روی نیمه ای از خط AB به طول $\frac{d}{2}$ انجام می‌دهیم که مرکز خط p روی آن قرار گرفته. در اینجا مرکز p روی AM قرار گرفته است. پس روی آن متمرکز می‌شویم.

دو حالت وجود دارد که در این دو حالت پاسخ را به دست می‌آوریم:
حالات اول: $L < d$

در این حالت می‌خواهیم احتمال آنکه خط به مرکز C با فاصله‌ی x از A , خط α_1 را قطع کند را حساب کنیم. تحلیل زیر را انجام می‌دهیم. برای حالتی که $|AC| < L/2$, با شروع از خط AC فرض کنیم بزرگترین زاویه‌ای که خط p خط α_1 را قطع کند، برابر θ باشد



: که

$$\cos(\theta) = \frac{|AC|}{L/2} = \frac{x}{L/2} = \frac{2x}{L}$$

: پس

$$\theta = \cos^{-1} \frac{2x}{L}$$


در اینصورت احتمال اینکه خط p خط α_1 را قطع کند برابر است با:

$$\frac{\theta}{\frac{\pi}{2}} = \frac{2 \cos^{-1} \frac{2x}{L}}{\pi}$$

همچنین برای حالتی که $x = |AC| > L/2$ باشد چنین زاویه‌ای وجود ندارد و خط p امکان این را ندارد که α_1 را قطع کند. در نتیجه در $x > L/2$ این احتمال برابر صفر است. پس در کل احتمال اینکه خط p که مرکز آن روی AM است خط α_1 را قطع کند برابر است با:

$$\begin{aligned} \frac{1}{d} \int_0^{L/2} \frac{2 \cos^{-1} \frac{2x}{L}}{\pi} dx &= \frac{4}{d} \times \frac{1}{\pi} \int_0^{L/2} \cos^{-1} \frac{2x}{L} dx \\ &= \frac{4}{d} \times \frac{1}{\pi} \left(x \cos^{-1} \left(\frac{2x}{L} \right) - \frac{\sqrt{1 - \frac{4}{L^2} x^2}}{\frac{2}{L}} \right) \Big|_0^{\frac{L}{2}} \\ &= \frac{4}{d} \times \frac{1}{\pi} \left(\frac{1}{2} \right) \\ &= \frac{2L}{\pi d} \end{aligned}$$

حالت دوم: $L \geq d$ در این حالت می‌خواهیم احتمال آنکه خط به مرکز C با فاصله‌ی x از A , خط α_1 را قطع کند را حساب کنیم.



تحلیل زیر را انجام می‌دهیم. با شروع از خط CA فرض کنیم بزرگترین زاویه‌ای که خط p خط α_1 را قطع کند، برابر θ باشد که:

$$\cos(\theta) = \frac{|AC|}{L/2} = \frac{x}{L/2} = \frac{2x}{L}$$

پس :

$$\theta = \cos^{-1} \frac{2x}{L}$$

در اینصورت احتمال اینکه خط p خط α_1 را قطع کند برابر است با :

$$\frac{\theta}{\frac{\pi}{2}} = \frac{2 \cos^{-1} \frac{2x}{L}}{\pi}$$

پس احتمال اینکه خط p که مرکز آن روی AM است خط α_1 را قطع کند برابر است با :

$$\begin{aligned} \frac{1}{\frac{d}{2}} \int_0^{d/2} \frac{2 \cos^{-1} \frac{2x}{L}}{\pi} dx &= \frac{4}{d} \times \frac{1}{\pi} \int_0^{d/2} \cos^{-1} \frac{2x}{L} dx \\ &= \frac{4}{d} \times \frac{1}{\pi} \left(x \cos^{-1} \left(\frac{2x}{L} \right) - \frac{\sqrt{1 - \frac{4}{L^2} x^2}}{\frac{2}{L}} \right) \Big|_0^{\frac{d}{2}} \\ &= \frac{4}{d} \times \frac{1}{\pi} \left[\left(\frac{d}{2} \cos^{-1} \left(\frac{d}{L} \right) - \frac{\sqrt{1 - \frac{d^2}{L^2}}}{\frac{2}{L}} \right) - \left(-\frac{1}{\frac{2}{L}} \right) \right] \\ &= \frac{4}{d} \times \frac{1}{\pi} \left[\left(\frac{d}{2} \cos^{-1} \left(\frac{d}{L} \right) - \frac{\sqrt{L^2 - d^2}}{2} \right) + \left(\frac{L}{2} \right) \right] \\ &= \frac{2}{\pi} \cos^{-1} \left(\frac{d}{L} \right) - 2 \frac{\sqrt{L^2 - d^2}}{d\pi} + \frac{2L}{d\pi} \end{aligned}$$

پس در هر دو حالت، پاسخ نهایی به دست آمد.

۳ سوال سوم

۱.۳ قسمت آ

فرض کنید X یک متغیر تصادفی باشد که از یک توزیع با چگالی $f_X(x)$ آمده باشد. برای اینکه اثبات کنیم $P(X \geq \alpha) \leq \frac{E(X)}{\alpha}$ کافی است ثابت کنیم $\alpha P(X \geq \alpha) \leq E(X)$. از سمت چپ معادله شروع می‌کنیم. داریم :

$$\alpha P(X \geq \alpha) = \alpha \int_{\alpha}^{\infty} f_X(x) dx \quad (1)$$

$$= \int_{\alpha}^{\infty} \alpha f_X(x) dx \quad (2)$$

$$\leq \int_{\alpha}^{\infty} x f_X(x) dx \quad (3)$$

$$\leq \int_{-\infty}^{\infty} x f_X(x) dx \quad (4)$$

$$= E(X) \quad (5)$$

در ۱ از تعریف $P(X \geq \alpha)$ استفاده شد. برای رسیدن از ۱ به ۲ از خاصیت خطی بودن انتگرال استفاده شد. برای رسیدن از ۲ به ۳ از این ویژگی استفاده شد که x بین α و ∞ است. و در نهایت برای رسیدن از ۳ به ۴ از ویژگی مثبت بودن متغیر تصادفی X استفاده شد که عبارت ۴ نیز تعریف Expected Value است. پس با کتاب هم قرار دادن این معادلات داریم :

$$\alpha P(X \geq \alpha) \leq E(X) \rightarrow P(X \geq \alpha) \leq \frac{E(X)}{\alpha}$$

لطفاً توجه شود که از فرض $\alpha > 0$ استفاده شد در حالی که این فرض جزو مفروضات سوال نبود. برای این مورد اگر فرض کنیم $0 < \alpha$ در آن صورت خواهیم داشت $P(X \geq \alpha) = 1$ و به دلیل مثبت بودن متغیر تصادفی X خواهیم داشت $0 < \frac{E(X)}{\alpha}$. پس در این حالت نامساوی برقرار نمی‌باشد.

نتیجه اینکه باید شرط $0 < \alpha$ نیز به شرط مسئله اضافه گردد.

۲.۳ قسمت ب

برای متغیر تصادفی دلخواه Z ، متغیر تصادفی $(Z - \mu)^2$ یک متغیر تصادفی نامنفی است. اگر در نامساوی مارکوف قرار دهیم $\alpha = \epsilon^2$ و $X = (Z - \mu)^2$ ، در آن صورت هر دو شرط نامساوی مارکوف (مثبت بودن X و α) برقرار است و داریم :

$$P((Z - \mu)^2 \geq \epsilon^2) \leq \frac{E[(Z - \mu)^2]}{\epsilon^2} \quad (6)$$

ابتدا طبق تعریف واریانس :

$$\sigma^2 = Var(Z) = E[(Z - E[Z])^2] = E[(Z - \mu)^2]$$

اگر این عبارت را در معادله ۶ قرار دهیم معادله ۶ به شکل زیر ساده می‌شود :

$$P((Z - \mu)^2 \geq \epsilon^2) \leq \frac{\sigma^2}{\epsilon^2}$$

همچنانی عبارت $(Z - \mu)^2 \geq \epsilon^2$ فقط در صورتی برقرار است که $Z - \mu \geq \epsilon$ و یا $Z - \mu \leq -\epsilon$ که مجموع این دو عبارت معادل است با اینکه :

$$|Z - \mu| \geq \epsilon$$

پس با بازنویسی معادله طبق شرط ساده شده داریم :

$$P(|Z - \mu| \geq \epsilon) \leq \frac{\sigma^2}{\epsilon^2}$$

که همان نامساوی چبیشف است.

در این قسمت هم باید نکته ای اشاره شود. در بخشی که از توان ۲ به قدر مطلق ساده سازی کردم این فرض باید وجود میداشت که $0 < \epsilon$ زیرا در غیر اینصورت اگر $\epsilon = 0$ می‌بود، در آن صورت $P((Z - \mu) \geq \epsilon) = 1$ است و در نتیجه نامساوی چبیشف به $\frac{\sigma^2}{\epsilon^2} \leq 1$ تبدیل می‌شود. در حالی که این نامساوی همیشه برقرار نیست.

نتیجه اینکه باید $0 < \epsilon$ جزو شرط مساله آورده می‌شد و در غیر اینصورت نامساوی برقرار نیست.

۳.۳ قسمت پ

۱.۳.۳ قسمت پ ۱

برای این قسمت از سوال متغیر تصادفی Z را به شکل زیر در نظر می‌گیریم

$$Z = \begin{cases} 1 & \text{if selected point be in the circle} \\ 0 & \text{if selected point be out of the circle} \end{cases}$$

از آنجایی که احتمال اینکه یک نقطه درون دایره بيقتد برابر تقسیم مساحت دایره بر مساحت مربع است پس هر نقطه به احتمال $p = \frac{\pi}{4}$ درون دایره می‌افتد و به احتمال $1 - p = q = 1 - \frac{\pi}{4}$ بیرون آن. در نتیجه متغیر تصادفی Z به احتمال p مقدار ۱ و به احتمال $1 - p = q = 1 - \frac{\pi}{4}$ مقدار ۰ می‌گیرد. پس Z یک متغیر تصادفی برنولی است. در مورد متغیر تصادفی برنولی می‌دانیم :

$$\begin{aligned} E(Z) &= p = \frac{\pi}{4} \\ Var(Z) &= p(1 - p) = \frac{\pi}{4}(1 - \frac{\pi}{4}) \end{aligned}$$

ما به دنبال تخمین مساحت دایره هستیم. از آنجایی که مساحت دایره برابر احتمال انتخاب نقطه درون دایره ضرب در مساحت مربع است و چون مساحت مربع ۴ است، پس ما به دنبال تخمین متغیر تصادفی $X = 4Z$ هستیم. طبق خواص Expected Value و Variance داریم :

$$\begin{aligned} E(X) &= 4E(Z) = 4p = \pi \\ Var(X) &= 4^2 Var(Z) = 16p(1 - p) = \pi(4 - \pi) \end{aligned}$$

حال m سمپل از X بر می‌داریم و آن‌ها را X_1, X_2, \dots, X_m می‌نامیم. متغیر تصادفی \bar{X} را به شکل زیر تعریف می‌کنیم :

$$\bar{X} = \frac{\sum_{i=1}^m X_i}{m} = \frac{X_1 + X_2 + \dots + X_m}{m}$$

طبق خواص Expected Value و Variance داریم :

$$\begin{aligned} E(\bar{X}) &= E(X) = \pi \\ Var(\bar{X}) &= \frac{1}{m} Var(X) = \frac{\pi}{m}(4 - \pi) \end{aligned}$$

می‌خواهیم با استفاده از نامساوی چبیشف با خطای ۰.۰۱ و با قاطعیت ۰.۹۵ مقدار \bar{X} را تخمین بزنیم. طبق این نامساوی داریم :

$$P(|\bar{X} - E(\bar{X})| \geq \epsilon) \leq \frac{Var(\bar{X})}{\epsilon^2}$$

با جایگذاری خطای تخمین مورد نظر ($\epsilon = 0.01$) داریم :

$$P(|\bar{X} - E(\bar{X})| \geq 10^{-2}) \leq \frac{Var(\bar{X})}{10^{-4}}$$

حال $Var(\bar{X})$ و $E(\bar{X})$ را جایگذاری می‌کنیم.

$$P(|\bar{X} - \pi| \geq 10^{-2}) \leq \frac{\pi(4 - \pi)}{10^{-4}m} = 10^4 \frac{\pi(4 - \pi)}{m}$$

از آنجایی که می‌خواهیم به قاطعیت ۹۵ درصد برسیم پس می‌خواهیم احتمال Bad Event حداقل ۵ درصد شود. پس سمت راست این نامساوی را کمتر از ۰.۰۵ قرار می‌دهیم. داریم :

$$10^4 \frac{\pi(4 - \pi)}{m} \leq 5 \times 10^{-2}$$

پس

$$m \geq \frac{1}{5} \times 10^6 \pi(4 - \pi) = 539353.2426\dots$$

در نتیجه برای رسیدن به این قاطعیت و دقت باید حداقل ۵۳۹,۳۵۴ نمونه طبق نامساوی چبیشف داشته باشیم. البته این نامساوی باند خوبی ارائه نمیدهد و با تعداد کمتری نمونه نیز می‌توان به همین دقت رسید که توسط نامساوی هافدینگ به دست خواهد آمد.

۲.۳.۳ قسمت ب ۲

با همان فرموله بندی ارائه شده در بخش قبلی پیش می‌رویم. (طبق برگه ارائه شده مژور نامساوی های احتمالاتی) نامساوی هافدینگ به شکل زیر تعریف می‌شود : اگر Z_1, Z_2, \dots, Z_m دنباله‌ای از متغیرهای تصادفی $i.i.d$ باشند و $E[\bar{Z}] = \mu$ و $P(a \leq Z_i \leq b) = 1$ در اینصورت برای هر $0 < \epsilon$ داریم :

$$P[|\bar{Z} - \mu| > \epsilon] \leq 2 \exp\left(\frac{-2M\epsilon^2}{(b-a)^2}\right) \quad (7)$$

حال طبق تعریف متغیر تصادفی X مقدار آن همواره یا ۰ و یا ۴ است. پس داریم :

$$P(0 \leq X_i \leq 4) = 1$$

با جایگذاری $a = 0$ و $b = 4$ در نامساوی ۷ داریم :

$$P[|\bar{X} - \pi| > \epsilon] \leq 2 \exp\left(\frac{-2M\epsilon^2}{(4-0)^2}\right) = 2 \exp\left(\frac{-M\epsilon^2}{8}\right)$$

حال چون می‌خواهیم دقت تخمین ۱ درصد باشد قرار می‌دهیم $\epsilon = 0.01$ و داریم :

$$P[|\bar{X} - \pi| > 0.01] \leq 2 \exp\left(\frac{-M \times 10^{-4}}{8}\right)$$

چون می‌خواهیم احتمال Bad Event حداقل ۵ درصد باشد قرار می‌دهیم :

$$2 \exp\left(\frac{-M \times 10^{-4}}{8}\right) \leq 0.05$$

یعنی :

$$\exp\left(\frac{-M \times 10^{-4}}{8}\right) \leq 0.025$$

برای حل این نامساوی از دو طرف \ln می‌گیریم :

$$\frac{-M \times 10^{-4}}{8} \leq \log_e(0.025)$$

پس :

$$\frac{M \times 10^{-4}}{8} \geq -\log_e(0.025)$$

در نتیجه :

$$M \geq -\log_e(0.025) \times 8 \times 10^4 = 295110.3563\dots$$


پس در این حالت نیز حداقل ۲۹۵,۱۱۱ داده برای رسیدن به چنین دقت و قاطعیتی نیاز است.

۴ سوال چهارم

۱.۴ قسمت آ

برای تابع AND و OR ، فرض کنیم خروجی ۱ دارای برچسب $+1$ و خروجی ۰ دارای برچسب -1 باشد. برای تابع AND دو ورودی، مدلسازی به شکل زیر خواهد بود (نقاط با برچسب -1 با رنگ قرمز و نقاط با برچسب $+1$ با رنگ سبز در شکل آمده اند): مدلسازی پرسپترون به شکل زیر انجام می شود

x_1	x_2	y
0	0	-1
0	1	-1
1	0	-1
1	1	+1



$$h(x) = \text{sign}(w_0 + w_1 x_1 + w_2 x_2)$$


با قرار دادن چهار سطر جدول در این رابطه داریم :

$$\begin{aligned} -1 &= \text{sign}(w_0) && \Rightarrow w_0 < 0 \\ -1 &= \text{sign}(w_0 + w_2) && \Rightarrow w_0 + w_2 < 0 \\ -1 &= \text{sign}(w_0 + w_1) && \Rightarrow w_0 + w_1 < 0 \\ +1 &= \text{sign}(w_0 + w_1 + w_2) && \Rightarrow w_0 + w_1 + w_2 > 0 \end{aligned}$$

دستگاه معادلات بالا دارای بی شمار پاسخ است. به عنوان مثال $(w_0, w_1, w_2) = (-1, 0.9, 0.9)$ یک پاسخ ممکن است که در شکل بالا با رنگ آبی مشخص شده است.

برای تابع OR ، مدلسازی به شکل زیر خواهد بود :

x_1	x_2	y
0	0	-1
0	1	+1
1	0	+1
1	1	+1




اگر سطرهای جدول را در معادله‌ی پرسپترون که در بالا آمد، قرار دهیم داریم :

$$\begin{aligned} -1 &= \text{sign}(w_0) && \Rightarrow w_0 < 0 \\ +1 &= \text{sign}(w_0 + w_2) && \Rightarrow w_0 + w_2 > 0 \\ +1 &= \text{sign}(w_0 + w_1) && \Rightarrow w_0 + w_1 > 0 \\ +1 &= \text{sign}(w_0 + w_1 + w_2) && \Rightarrow w_0 + w_1 + w_2 > 0 \end{aligned}$$

دستگاه معادلات بالا دارای بی شمار پاسخ است. به عنوان مثال $(w_0, w_1, w_2) = (-1, 2, 2)$ یک پاسخ ممکن است که در شکل بالا با رنگ آبی مشخص شده است.

۲.۴ قسمت ب

تابع XOR به شکل زیر مدلسازی می‌شود



اگر پرسپترون بتواند با موفقیت دسته‌بندی را انجام دهد، فرض کنید در نقطه‌ای که به این موفقیت رسیده است دارای بردار وزن (w_0, w_1, w_2) باشد. رابطه‌ی پرسپترون به شکل زیر است

$$h(x) = sign(w_0 + w_1x_1 + w_2x_2)$$

با جایگذاری سطر های جدول در این رابطه داریم :

$$-1 = sign(w_0) \Rightarrow w_0 < 0 \quad (8)$$

$$+1 = sign(w_0 + w_2) \Rightarrow w_0 + w_2 > 0 \quad (9)$$

$$+1 = sign(w_0 + w_1) \Rightarrow w_0 + w_1 > 0 \quad (10)$$

$$-1 = sign(w_0 + w_1 + w_2) \Rightarrow w_0 + w_1 + w_2 < 0 \quad (11)$$

از ۸ و ۹ نتیجه می‌شود :

$$w_2 > 0 \quad (12)$$

از ۱۲ و ۱۰ هم نتیجه می‌شود :

$$w_0 + w_1 + w_2 > 0$$

که با ۱۱ در تناقض است. پس مدلسازی پرسپترون با خطای صفر برای این تابع وجود ندارد.

۳.۴ قسمت ب

فرض کنیم بردار وزن اولیه‌ی پرسپترون $w_0 = 0$ باشد. همچنین فرض کنیم در هر مرحله داده‌ی با اندیس i α_i به اشتیاه دسته‌بندی شود. یعنی در مرحله‌ی اول داده‌ی α_1 ام دچار misclassify می‌شود و بردار وزن به شکل $w_1 = w_0 + x_{\alpha_1}y_{\alpha_1}$ درمی‌آید. سپس در مرحله‌ی دوم داده‌ی α_2 ام دچار misclassify می‌شود و بردار وزن به شکل $w_2 = w_1 + x_{\alpha_2}y_{\alpha_2}$ درمی‌آید و به همین شکل بالایی برای اندازه بردار وزن در مرحله‌ی k پیدا کنیم. از جبر خطی می‌دانیم اگر β و η دو بردار به طول n باشند، داریم :

$$\begin{aligned} \|\beta + \eta\|^2 &= (\beta_1 + \eta_1)^2 + \dots + (\beta_n + \eta_n)^2 \\ &= (\beta_1^2 + \dots + \beta_n^2) + (\eta_1^2 + \dots + \eta_n^2) + 2(\beta_1\eta_1 + \dots + \beta_n\eta_n) \\ &= \|\beta\|^2 + \|\eta\|^2 + 2\langle\beta, \eta\rangle \end{aligned}$$

$$\|w_k\|^2 = \|w_{k-1} + x_{\alpha_k} y_{\alpha_k}\|^2 \quad (13)$$

$$= \|w_{k-1}\|^2 + \|x_{\alpha_k} y_{\alpha_k}\|^2 + 2\langle w_{k-1}, x_{\alpha_k} y_{\alpha_k} \rangle \quad (14)$$

$$= \|w_{k-1}\|^2 + \|x_{\alpha_k}\|^2 + 2y_{\alpha_k} \langle w_{k-1}, x_{\alpha_k} \rangle \quad (15)$$

$$\leq \|w_{k-1}\|^2 + \|x_{\alpha_k}\|^2 \quad (16)$$

$$\leq \|w_{k-1}\|^2 + r^2 \quad (17)$$

چون $\{ -1, +1 \}$ از ۱۴ به ۱۵ رسیدیم. برای اینکه بتوانیم از ۱۵ به ۱۶ برسیم، توجه داشته باشد که سیستم روی داده‌ی α_k ام دچار خطای دسته‌بندی شده است پس عبارت $2y_{\alpha_k} \langle w_{k-1}, x_{\alpha_k} \rangle$ منفی است. برای رسیدن از ۱۶ به ۱۷ از فرض سوال استفاده کردیم.
حال اگر این نامساوی را تا صفر ادامه دهیم داریم :

$$\|w_k\|^2 \leq \|w_0\|^2 + kr^2 = kr^2 \quad (18)$$

حال به سراغ یافتن کران پایینی برای ضرب داخلی w^* و w_k می‌رویم. داریم:

$$\langle w^*, w_k \rangle = \langle w^*, w_{k-1} + x_{\alpha_k} y_{\alpha_k} \rangle \quad (19)$$

$$= \langle w^*, w_{k-1} \rangle + \langle w^*, x_{\alpha_k} y_{\alpha_k} \rangle \quad (20)$$

$$= \langle w^*, w_{k-1} \rangle + y_{\alpha_k} \langle w^*, x_{\alpha_k} \rangle \quad (21)$$

$$\geq \langle w^*, w_{k-1} \rangle + \rho \quad (22)$$

برای رسیدن از ۱۹ به ۲۰ از خاصیت پخشی ضرب داخلی استفاده می‌کنیم. برای رسیدن از ۲۰ به ۲۱ از مولفه‌ی دوم ضرب داخلی، عنصر y_{α_k} را استخراج کرده ایم. در نهایت برای رسیدن از ۲۱ به ۲۲ از فرض سوال استفاده کردیم. نتیجه اینکه اگر این نامساوی را تا رسیدن به $k = 0$ ادامه دهیم خواهیم داشت:

$$\langle w^*, w_k \rangle \geq \langle w^*, w_0 \rangle + k\rho \quad (23)$$

از جبر خطی می‌دانیم اگر β و η دو بردار باشند، داریم :

$$\langle \beta, \eta \rangle \leq \|\beta\| \|\eta\| \quad (24)$$

داریم :

$$\langle w^*, w_k \rangle \leq \|w^*\| \|w_k\| \quad (25)$$

$$= \|w_k\| \quad (26)$$

که برای رسیدن از ۲۵ به ۲۶ از این فرض استفاده شد که $\|w^*\| = 1$ از ترکیب ۲۳ و ۲۶ داریم :

$$\|w_k\| \geq \langle w^*, w_0 \rangle + k\rho$$

چون $w_0 = 0$ پس :

$$\|w_k\| \geq k\rho \quad (27)$$

از جمع بندی ۱۸ و ۲۷ داریم :

$$(k\rho)^2 \leq \|w_k\|^2 \leq kr^2 \Rightarrow k \leq \left(\frac{r}{\rho}\right)^2$$

۵ سوال پنجم

۱.۵ قسمت آ

خیر. به عنوان مثال اگر ما بدانیم بوده باشیم و همهی نمونهای درون \mathcal{D} برچسب ۱ داشته باشند، در اینصورت A_1 فرضیهی h_2 را انتخاب می‌کند که کمترین خطای را روی \mathcal{D} دارد. دقت آن عبارتست از:

$$\begin{aligned} P(f(x) = h_2(x)) &= P(f(x) = +1, h_2(x) = +1) + P(f(x) = -1, h_2(x) = -1) \\ &= P(f(x) = +1)P(h_2(x) = +1) + P(f(x) = -1)P(h_2(x) = -1) \\ &= p \times (0) + (1-p) \times (1) \\ &= 1-p \end{aligned}$$

اگر h فرضیهای باشد که انتخاب تصادفی دارد. دقت h عبارتست از:

$$\begin{aligned} P(f(x) = h(x)) &= P(f(x) = +1, h(x) = +1) + P(f(x) = -1, h(x) = -1) \\ &= P(f(x) = +1)P(h(x) = +1) + P(f(x) = -1)P(h(x) = -1) \\ &= p \times \frac{1}{2} + (1-p) \times \frac{1}{2} \\ &= \frac{1}{2} \end{aligned}$$

که برای به دست آوردن این احتمالات از استقلال h و f استفاده شده است.
همانطور که مشخص است A_1 نمی‌تواند تضمین دهد که از انتخاب تصادفی عملکرد بهتری دارد. زیرا اگر $p > 1/2$ باشد، حالت تصادفی دقت بالاتری خواهد داشت.

از این قسمت به بعد به دلیل اینکه همهی عناصر \mathcal{D} دارای برچسب ۱ هستند، پس الگوریتم A_1 فرضیهی h_2 را انتخاب می‌کند.

۲.۵ قسمت ب

بله ممکن است A_2 بهتر از A_1 باشد. اگر ما بدانیم بوده باشیم و داده‌های خارج از \mathcal{D} بیشتر دارای برچسب ۱ باشند، در اینصورت A_2 فرضیهی بهتری تولید می‌کند. در حالت کلی دقت A_1 برابر است با:

$$\begin{aligned} P(f(x) = h_1(x)) &= P(f(x) = +1, h_1(x) = +1) + P(f(x) = -1, h_1(x) = -1) \\ &= P(f(x) = +1)P(h_1(x) = +1) + P(f(x) = -1)P(h_1(x) = -1) \\ &= p \times 1 + (1-p) \times 0 \\ &= p \end{aligned}$$

و دقت A_2 برابر است با:

$$\begin{aligned} P(f(x) = h_2(x)) &= P(f(x) = +1, h_2(x) = +1) + P(f(x) = -1, h_2(x) = -1) \\ &= P(f(x) = +1)P(h_2(x) = +1) + P(f(x) = -1)P(h_2(x) = -1) \\ &= p \times (0) + (1-p) \times (1) \\ &= 1-p \end{aligned}$$

حال اگر $p < 0.5$ در آن صورت A_2 الگوریتم بهتری است.

۳.۵ قسمت پ

در این بخش فرض کنیم n نمونه‌ی تست داریم. به شکل *Expected* برچسب داده‌ها برابر $(1)(p) + (-1)(1-p) = 2p - 1 = 0.8$ است. حال اگر فقط روی n نمونه بحث کنیم اگر مقدار متوسط برچسب‌های این n نمونه بزرگتر از صفر باشد، نشان دهنده‌ی این است که الگوریتم A_1 با انتخاب h_1 به پاسخ بهتری می‌رسد و اگر مقدار متوسط این برچسب‌ها کمتر از صفر باشد، الگوریتم A_2 با انتخاب h_2 ما را به پاسخ بهتری می‌رساند. اگر برچسب‌های این n نمونه را y_1, y_2, \dots, y_n بنامیم در این صورت احتمال اینکه این میانگین کمتر از صفر شود طبق نامساوی هافدینگ برابر است با:

$$P\left(\left|\frac{1}{n} \sum_{i=1}^n y_i - \underbrace{0.8}_{\text{expected value of } y}\right| > 0.8\right) \leq 2e^{-2(0.8)^2 n}$$

توجه شود که از آنجایی که حدکثر برابر مقدار 1 است پس عملای فقط زمانی *BadEvent* رخ می‌دهد که $\frac{1}{n} \sum_{i=1}^n y_i < 0$ مدققاً همان *BadEvent* مدنظر ماست و نشان دهنده‌ی احتمال بهتر بودن A_2 نسبت به A_1 است.

حال برای استفاده از نامساوی هافدینگ اگر فرض کنیم $\infty \rightarrow n$ در آن صورت $0 \rightarrow 2e^{-2(0.8)^2 n}$. به عبارتی:

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n y_i - 0.8\right| > 0.8\right) \leq \lim_{n \rightarrow \infty} 2e^{-2(0.8)^2 n} = 0$$

پس برای n های بزرگ A_1 به احتمال 1 فرضیه‌ی بهتری نسبت به A_2 ایجاد می‌کند.

۴.۵ قسمت ت

برای $p < 0.5$ به احتمال زیادی A_2 فرضیه‌ی بهتری نسبت به A_1 تولید می‌کند. همانطور که قبل محاسبه شد مقادیر y برابر مقدار زیر است:

$$E = (1)(p) + (-1)(1-p) = 2p - 1$$

حال می‌خواهیم احتمال بهتر بودن فرضیه‌ی A_1 بر A_2 را محاسبه کنیم. در صورتی A_1 فرضیه‌ی بهتری را تولید می‌کند که میانگین مقادیر y_i از صفر بزرگتر باشد. در اینصورت تعداد نمونه‌های مثبت تست از نمونه‌های منفی بیشتر بوده است. پس A_1 با انتخاب $+1$ ($h_1(x) = +1$) فرضیه‌ی بهتری تولید می‌کند. طبق مفاهیم قدر مطلق می‌دانیم:

$$if |p| \geq b, b > 0 \text{ then } p \leq -b \text{ or } p \geq b$$

پس داریم:

$$\begin{aligned} P\left(\left|\frac{1}{n} \sum_{i=1}^n y_i - (2p - 1)\right| \geq 1 - 2p\right) &= P\left(\frac{1}{n} \sum_{i=1}^n y_i - (2p - 1) \geq 1 - 2p\right) + P\left(\frac{1}{n} \sum_{i=1}^n y_i - (2p - 1) \leq 2p - 1\right) \\ &= P\left(\frac{1}{n} \sum_{i=1}^n y_i \geq 0\right) + P\left(\frac{1}{n} \sum_{i=1}^n y_i - (2p - 1) \leq 2p - 1\right) \end{aligned}$$

پس نتیجه می‌شود:

$$P\left(\frac{1}{n} \sum_{i=1}^n y_i \geq 0\right) \leq P\left(\left|\frac{1}{n} \sum_{i=1}^n y_i - (2p - 1)\right| \geq 1 - 2p\right) \quad (28)$$

همچنین طبق نامساوی هافدینگ داریم:

$$P\left(\left|\frac{1}{n} \sum_{i=1}^n y_i - (2p - 1)\right| \geq 1 - 2p\right) \leq 2e^{-2(1-2p)^2 n} \quad (29)$$

با کنار هم قرار دادن ۲۸ و ۲۹ داریم :

$$\begin{aligned} P\left(\frac{1}{n} \sum_{i=1}^n y_i \geq 0\right) &\leq P\left(\left|\frac{1}{n} \sum_{i=1}^n y_i - (2p-1)\right| \geq 1-2p\right) \\ &\leq 2e^{-2(1-2p)^2 n} \end{aligned}$$

و به شکل خلاصه تر :

$$P\left(\frac{1}{n} \sum_{i=1}^n y_i \geq 0\right) \leq 2e^{-2(1-2p)^2 n}$$

از آنجایی که $0 < 1-2p < 1$ داریم :

$$\lim_{n \rightarrow \infty} P\left(\frac{1}{n} \sum_{i=1}^n y_i \geq 0\right) \leq \lim_{n \rightarrow \infty} 2e^{-2(1-2p)^2 n} = 0$$

پس برای n های به اندازه کافی بزرگ، الگوریتم A_1 نمیتواند به خوبی A_2 عمل کند و به احتمال بسیار زیاد فرضیه های بهتری تولید می کند.