

پاسخ سری پنجم تمرینات درس یادگیری ماشین

امیرحسین رمضانی بناب (۹۹۲۱۰۲۹۴)

۱ سوال ۱

۱.۱ آ

نشان می‌دهیم در نقطه‌ی بهینه خواهیم داشت

$$\forall n : \xi_n \geq 0$$

فرض کنیم یک داده داشته باشیم که $\xi_i < 0$. در آن صورت داریم:

$$y^{(i)}(\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1 + |\xi_i|$$

حال اگر ξ_i را تبدیل به صفر کنیم، اولاً تابع هدف کاهش می‌یابد. ثانیاً شرایط مساله نقض نمی‌شود زیرا

$$y^{(i)}(\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1 + |\xi_i| \geq 1$$

پس همچنان برای تمام نقاط شرایط مسئله برقرار است و تابع هدف نیز کاهش یافته است. که این با بهینه‌بودن ξ_n در تناقض است.

۲.۱ ب

با استفاده از ضرایب لاگرانژ به مسئله‌ی زیر خواهیم رسید

$$\mathcal{L}(\mathbf{w}, b, \xi, \alpha, \beta) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + \frac{C}{2} \sum_{n=1}^N \xi_n^2 - \sum_{n=1}^N \alpha_n (y_n (\mathbf{w}^T \mathbf{x}_n + b) - 1 + \xi_n)$$

باید این عبارت را نسبت به \mathbf{w} و b و ξ کمینه و نسبت به $\alpha \geq 0$ بیشینه کنیم. داریم:

$$\nabla_{\mathbf{w}} \mathcal{L} = \mathbf{w} - \sum_{n=1}^N \alpha_n y_n \mathbf{x}_n = 0 \quad \Rightarrow \quad \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{x}_n \quad (*)$$

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_{n=1}^N \alpha_n y_n = 0 \quad \Rightarrow \quad \sum_{n=1}^N \alpha_n y_n = 0$$

$$\frac{\partial \mathcal{L}}{\partial \xi_n} = C \xi_n - \alpha_n = 0 \quad \Rightarrow \quad \xi_n = \frac{\alpha_n}{C} \quad (**)$$

۳.۱ ب

با جایگذاری عبارات بالا در \mathcal{L} خواهیم داشت

$$\mathcal{L}(\alpha) = \sum_{n=1}^N \alpha_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N y_n y_m \alpha_n \alpha_m \mathbf{x}_n^T \mathbf{x}_m - \frac{1}{2C} \sum_{n=1}^N \alpha_n^2$$

با توجه به اینکه همیشه برای $y_n \in \{-1, +1\}$ داریم

$$y_n y_n = +1$$

دو عبارت جمع بالا را در یک عبارت خلاصه می‌کنیم

$$\mathcal{L}(\alpha) = \sum_{n=1}^N \alpha_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N y_n y_m \alpha_n \alpha_m (\mathbf{x}_n^T \mathbf{x}_m + \frac{\delta_{ij}}{C})$$

که δ_{ij} تابعی است که در $j = i$ مقدار ۱ و در بقیه نقاط مقدار ۰ دارد.
به این ترتیب، هدف کمینه کردن \mathcal{L} است به شکلی که

$$\forall n : \sum_{n=1}^N \alpha_n y_n = 0, \alpha_i \geq 0$$

۴.۱ ت

وقتی $C \rightarrow \infty$ مسئله‌ی بهینه‌سازی زیر را خواهیم داشت:

$$\text{minimize } \mathcal{L}(\alpha) = \sum_{n=1}^N \alpha_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N y_n y_m \alpha_n \alpha_m \mathbf{x}_n^T \mathbf{x}_m$$

که

$$\forall n : \sum_{n=1}^N \alpha_n y_n = 0, \alpha_i \geq 0$$

این همان مسئله‌ی بهینه‌سازی Hard Margin SVM است.
وقتی $C \rightarrow 0$ از رابطه‌ی ** داریم

$$C \xi_n - \alpha_n = 0 \Rightarrow \alpha_n = 0$$

در نتیجه از رابطه‌ی * داریم

$$\mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{x}_n = 0$$

پس در این حالت همه‌ی وزن‌ها برابر صفر می‌شوند و عملاً دسته‌بندی انجام نخواهد شد.

۲ سوال ۲

با توجه به اینکه در صورت سوال گفته شده است که هسته‌های k_1 و k_2 معتبر هستند. فرض کنیم ماتریس این هسته‌ها را با K_1 و K_2 نشان دهیم و همچنین تعداد داده‌ها را N در نظر بگیریم. باید دو شرط زیر را بررسی نماییم:

$$\begin{aligned} k_i(x_1, x_2) &= k_i(x_2, x_1) \quad \text{for } i = 1, 2 \\ \forall a \in \mathbb{R}^N : a^\top K_i a &\succeq 0 \quad \text{for } i = 1, 2 \end{aligned}$$

۱.۲

برای هسته‌ی k_3 آن دو ویژگی را بررسی می‌کنیم.
شرط اول:

$$\begin{aligned} k_3(x_2, x_1) &= k_1(x_2, x_1) + k_2(x_2, x_1) \\ &= k_1(x_1, x_2) + k_2(x_1, x_2) \\ &= k_3(x_1, x_2) \end{aligned}$$

پس شرط اول برقرار است.
شرط دوم:

$$\begin{aligned} \forall a \in \mathbb{R}^N : a^\top K_3 a &= a^\top (K_1 + K_2) a \\ &= a^\top K_1 a + a^\top K_2 a \\ &\succeq 0 \end{aligned}$$

پس شرط دوم برقرار است و هسته معتبر است.

۲.۲

برای هسته‌ی k_4 از معتبر بودن هسته‌های k_1 و k_2 استفاده می‌کنیم. از آنجایی که این دو هسته معتبر هستند، اگر فضای نمونه‌های مسئله را \mathcal{X} بنامیم و فضاهای جدید را با \mathcal{Z}_i نمایش دهیم دو تابع زیر را داریم:

$$\begin{aligned} \Phi_1 : \mathcal{X} &\rightarrow \mathcal{Z}_1 \\ \Phi_2 : \mathcal{X} &\rightarrow \mathcal{Z}_2 \end{aligned}$$

که

$$\begin{aligned} k_1(x_1, x_2) &= \Phi_1(x_1)^\top \Phi_1(x_2) \\ k_2(x_1, x_2) &= \Phi_2(x_1)^\top \Phi_2(x_2) \end{aligned}$$

اگر فرض کنیم

$$\begin{aligned} \Phi_1(x_i) &= \langle \alpha_1^{(i)}, \alpha_2^{(i)}, \dots, \alpha_N^{(i)} \rangle \\ \Phi_2(x_i) &= \langle \beta_1^{(i)}, \beta_2^{(i)}, \dots, \beta_M^{(i)} \rangle \end{aligned}$$

خواهیم داشت

$$\begin{aligned} k_1(x_1, x_2) &= \sum_{i=1}^N \alpha_i^{(1)} \alpha_i^{(2)} \\ k_2(x_1, x_2) &= \sum_{i=1}^M \beta_i^{(1)} \beta_i^{(2)} \end{aligned}$$

$$\begin{aligned}
k_4(x_1, x_2) &= k_1(x_1, x_2)k_2(x_1, x_2) \\
&= \left(\sum_{i=1}^N \alpha_i^{(1)} \alpha_i^{(2)} \right) \left(\sum_{i=1}^M \beta_i^{(1)} \beta_i^{(2)} \right) \\
&= \sum_{i=1}^N \sum_{j=1}^M \alpha_i^{(1)} \alpha_i^{(2)} \beta_j^{(1)} \beta_j^{(2)} \\
&= \sum_{i=1}^N \sum_{j=1}^M [\alpha_i^{(1)} \beta_j^{(1)}] [\alpha_i^{(2)} \beta_j^{(2)}] \\
&= \sum_{i=1}^N \sum_{j=1}^M [\gamma_{ij}^{(1)}] [\gamma_{ij}^{(2)}] \\
&= \gamma(x_1)^T \gamma(x_2)
\end{aligned}$$

که در عبارت بالا

$$\gamma_{ij}^{(k)} = \alpha_i^{(k)} \beta_j^{(k)}$$

و $\gamma(x_k)$ یک ماتریس $N \times M$ (معادل یک بردار NM بعدی) است که:

$$\gamma(x_k)[i, j] = \gamma_{ij}^{(k)}$$

پس چون توانستیم هسته را به شکل ضرب داخلی این دو بردار بنویسیم، این هسته معتبر می‌باشد.

۳.۲

برای هسته k_5 از سری تیلور استفاده می‌کنیم. طبق بسط تیلور داریم

$$\forall i, j : e^{k_5(x_i, x_j)} = \sum_{n=0}^{n=\infty} \frac{k_5(x_i, x_j)^n}{n!}$$

پس اگر ماتریس کرنل k_5 را K_5 بنامیم داریم:

$$e^{K_5} = \sum_{n=0}^{n=\infty} \frac{K_5^n}{n!}$$

که تمام عملیات به صورت element-wise انجام می‌شود. از آنجایی که در قسمت‌های قبلی ثابت کردیم جمع و ضرب هسته‌ها به شکل element-wise هسته‌ی معتبری را می‌سازد، چون سری تیلور از مجموعه‌ای از ضرب و جمع element-wise ساخته شده است نیز هسته‌ی معتبری می‌سازد.

۴.۲

در این سوال از خاصیت "همگنی" که جزو خواص هسته‌های معتبر در سوال ۳ ذکر شده است، استفاده می‌کنیم. اگر k_6 یک هسته‌ی معتبر باشد پس باید داشته باشیم:

$$\forall \alpha \in \mathbb{R}_{++} : k_6(\alpha x_1, x_2) = \alpha k_6(x_1, x_2)$$

(البته این تعریف همگنی در کوئرا اصلاح شد و به اعداد منفی تعمیم یافت. ولی در این نقطه ما به اعداد منفی نیازی نداریم و فقط روی اعداد مثبت بررسی می‌کنیم)

پس

$$\frac{1}{1 - \alpha x_1^T x_2} = \frac{\alpha}{1 - x_1^T x_2}$$

یعنی

$$\alpha - \alpha^2 x_1^T x_2 = 1 - x_1^T x_2$$

پس

$$x_1^T x_2 = \frac{1}{1 + \alpha}$$

از آنجایی که $x_1^T x_2$ مقدار مشخصی دارد ولی تساوی به ازای هر α مثبت اتفاق می افتد به تناقض می رسیم. زیرا در آن صورت نتیجه می شود همه ی α های مثبت با هم برابرند! پس این هسته معتبر نیست.

ابتدا خاصیت همگنی را استفاده می‌کنیم تا یک نتیجه بگیریم:

$$x = 0 \Rightarrow f(0, y) = \alpha f(0, y) \Rightarrow f(0, y) = 0$$

حال از خاصیت افزایشی استفاده می‌کنیم. داریم:

$$f(x + (-x), y) = f(x, y) + f(-x, y)$$

پس

$$f(x, y) + f(-x, y) = 0 \Rightarrow f(-x, y) = -f(x, y)$$

از اینجا به بعد منظور از خاصیت همگنی، همین خاصیت است. از خواص تقارنی، افزایش و همگنی استفاده می‌کنیم تا h را ساده‌تر کنیم. داریم:

$$g(x + y, x + y) = g(x, x + y) + g(y, x + y) \quad (۱)$$

$$= g(x + y, x) + g(x + y, y) \quad (۲)$$

$$= g(x, x) + g(y, x) + g(x, y) + g(y, y) \quad (۳)$$

$$= g(x, x) + g(y, y) + 2g(x, y) \quad (۴)$$

در ۱ از خاصیت افزایشی، برای رسیدن به ۲ از خاصیت تقارنی، برای رسیدن به ۳ از خاصیت افزایشی و برای رسیدن به ۴ از خاصیت تقارنی استفاده شد. همچنین داریم:

$$g(x - y, x - y) = g(x, x - y) + g(-y, x - y) \quad (۵)$$

$$= g(x - y, x) - g(x - y, y) \quad (۶)$$

$$= g(x, x) + g(-y, x) - g(x, y) - g(-y, y) \quad (۷)$$

$$= g(x, x) - g(y, x) - g(x, y) + g(y, y) \quad (۸)$$

$$= g(x, x) + g(y, y) - 2g(x, y) \quad (۹)$$

در ۵ از خاصیت افزایشی، برای رسیدن به ۶ از خاصیت تقارنی و همگنی، برای رسیدن به ۷ از خاصیت افزایشی، برای رسیدن به ۸ از خاصیت همگنی و برای رسیدن به ۹ از خاصیت تقارنی استفاده شد.

حال داریم:

$$\begin{aligned} h(x, y) &= \frac{1}{4}(g(x + y, x + y) - g(x - y, x - y)) \\ &= \frac{1}{4}[(g(x, x) + g(y, y) + 2g(x, y)) - (g(x, x) + g(y, y) - 2g(x, y))] \\ &= \frac{1}{4}[4g(x, y)] \\ &= g(x, y) \end{aligned}$$

پس چون g یک کرنل معتبر است، h نیز چنین است.

۴ سوال ۴

فرض کنیم مجموعه‌ی متناهی M مجموعه‌ی مرجع ما باشد که n عضو دارد. قرار می‌دهیم $P = 2^M$. پس P مجموعه‌ی توانی M است. از آنجایی که P متناهی است عناصرش را به شکل زیر در نظر می‌گیریم

$$P = \{\zeta_1, \zeta_2, \dots, \zeta_{2^n}\}$$

حال برای مجموعه‌ی A تابع Φ را به شکل زیر تعریف می‌کنیم:

$$\Phi : P \rightarrow \{0, 1\}^{2^n}$$

که برای هر $A \in P$ داریم:

$$\Phi(A) = (\alpha_1, \alpha_2, \dots, \alpha_{2^n})$$

که

$$\alpha_i = \begin{cases} 1 & \zeta_i \subseteq A \\ 0 & \zeta_i \not\subseteq A \end{cases}$$

حال اگر $B \in P$ یک مجموعه باشد، و داشته باشیم

$$\Phi(B) = (\beta_1, \beta_2, \dots, \beta_{2^n})$$

که

$$\beta_i = \begin{cases} 1 & \zeta_i \subseteq B \\ 0 & \zeta_i \not\subseteq B \end{cases}$$

خواهیم داشت

$$\Phi(A)^\top \Phi(B) = \sum_{i=1}^{2^n} \alpha_i \beta_i = |\{i | 1 \leq i \leq 2^n : \alpha_i = 1 \wedge \beta_i = 1\}|$$

از آن جایی که

$$\begin{aligned} |\{i | 1 \leq i \leq 2^n : \alpha_i = 1 \wedge \beta_i = 1\}| &= |\{i | 1 \leq i \leq 2^n : \zeta_i \subseteq A \wedge \zeta_i \subseteq B\}| \\ &= |\{i | 1 \leq i \leq 2^n : \zeta_i \subseteq A \cap B\}| \\ &= 2^{|A \cap B|} \end{aligned}$$

پس

$$\Phi(A)^\top \Phi(B) = 2^{|A \cap B|}$$

حال چون

$$k(A, B) = 2^{|A \cap B|}$$

پس

$$k(A, B) = \Phi(A)^\top \Phi(B)$$

که نشان می‌دهد این هسته معتبر است.

۵ سوال ۵

در این سوال ابتدا از طریق هسته‌ی RBF به دقت حدود 90.3 درصدی رسیدیم و سپس با تغییر C به دقت 93.18 درصد دست یافتیم. دلیل بهبود دقت افزایش پارامتر C بود که منجر شد کمی از Regularization کاسته شود و به اهمیت Violation افزوده شود.